

Large Language Models

1. Introdução

Modelos de Linguagem de Grande Escala, conhecidos como LLMs (Large Language Models), são modelos de aprendizado profundo baseados na arquitetura de Transformers. Esses modelos revolucionaram o campo de Processamento de Linguagem Natural (NLP), permitindo a geração de texto, tradução automática, análise de sentimentos, resumo de textos, entre outras tarefas.

A principal característica dos LLMs é a geração condicional de texto, onde um prompt (texto de entrada) é utilizado como contexto para prever e gerar palavras subsequentes de maneira sequencial (token por token), mantendo coerência e coesão textual mesmo em longas sequências.

2. Geração de Texto

2.1 Mecanismo Autogerativo (Autoregressive)

O modelo realiza previsões sucessivas com base nas palavras anteriores. A cada passo, o texto gerado é reincorporado ao contexto, aproveitando ao máximo a janela de contexto do modelo para manter o significado.

2.2 Aplicações Práticas

- **Completar texto:** Previsão de sequência coerente a partir de um início.
- **Análise de sentimento:** Classificação implícita de polaridade.
- **Pergunta e resposta:** Respostas diretas a perguntas textuais.
- **Resumo automático:** Inserção de tokens específicos, como “tl;dr”, instrui o modelo a condensar o conteúdo.

2.3 Estratégias de Decodificação

- **Greedy Decoding:** Seleciona sempre o token mais provável; resulta em textos repetitivos.
- **Sampling (Amostragem):** Seleciona tokens aleatoriamente com base em sua probabilidade; promove variedade e naturalidade. É a abordagem preferida para gerar textos criativos e não determinísticos.

3. Aprendizado por Auto-Supervisão

3.1 Conceito

Nos LLMs, **auto-supervisão** significa que o modelo aprende com os próprios dados, sem rótulos manuais. O objetivo é prever a próxima palavra de uma sequência a partir do próprio texto.

3.2 Processo

1. Extração de sequência: $w_1, w_2, w_3, \dots, w_t$
2. Entrada no modelo: $w_1, \dots, w_t$
3. Previsão: próxima palavra w_{t+1}
4. Cálculo de erro: utilizando Cross-Entropy Loss

A Cross-Entropy Loss penaliza previsões incorretas comparando a distribuição prevista com a correta (one-hot vector).

3.3 Técnica: Teacher Forcing

Mesmo quando o modelo erra, na próxima etapa é forçado a usar a palavra correta como entrada, acelerando o treinamento.

4. Treinamento com Transformers

- **Paralelismo:** Diferente das RNNs, os Transformers processam tokens em paralelo.
- **Distribuição de Probabilidade:** Cada posição prevê todas as palavras do vocabulário.
- **Cálculo de Perda:** Média da perda de todas as posições.

5. Dados de Treinamento

Modelos como **GPT** são treinados com grandes corpora, como:

- **Common Crawl, Wikipedia,** livros, artigos, fóruns
- **The Pile** (825 GB)
- **Dolma** (3 trilhões de tokens)

Os dados são filtrados quanto à qualidade e segurança, removendo spam, duplicações, conteúdos ofensivos ou sensíveis.

6. Questões Éticas e Legais

- **Direitos Autorais:** Muitos dados têm copyright.
- **Consentimento:** Nem todos os sites permitem uso automatizado de dados.
- **Privacidade:** Riscos de vazamento de dados pessoais.

7. Avaliação de LLMs

7.1 Perplexidade

Indica a capacidade do modelo de prever texto ainda não visto.
→ Quanto menor a perplexidade, melhor a previsão.

Importante: Comparações de perplexidade só são válidas entre modelos com o mesmo tokenizador.

7.2 Outras Métricas

- **Acurácia por tarefa** (tradução, resumo, QA, etc.)
- **Tamanho do modelo**
- **Consumo de energia e recursos**
- **Justiça e vieses:**
 - Benchmarks: *StereoSet*, *RealToxicityPrompts*, *BBQ*
 - Avaliações com critérios Rawlsianos
 - Protocolos como *Dynabench* e *HELM*

8. Lidando com Escala

8.1 Tamanho de Modelos

Modelos como LLaMA 3.1 Instruct com 405 bilhões de parâmetros exigem hardware robusto e estratégias eficientes de escalonamento.

8.2 Leis de Escalonamento (Scaling Laws)

Desempenho depende de:

1. Parâmetros do modelo
2. Tamanho do dataset
3. Capacidade computacional

Relações seguem leis de potência, orientando o dimensionamento ideal.

8.3 Cache KV (Key-Value)

Na inferência, armazenar vetores K e V evita recomputações, acelerando o processo.

9. Ajuste Fino com Poucos Parâmetros (PEFT)

O ajuste fino completo é caro. Técnicas de PEFT (Parameter-Efficient Fine-Tuning), como o LoRA (Low-Rank Adaptation), ajustam apenas projeções de baixa dimensão. Isso reduz custo computacional sem comprometer significativamente o desempenho.

10. Conclusão

Os Large Language Models (LLMs) representam um avanço significativo na inteligência artificial, impulsionando o campo de NLP a novos patamares. Sua capacidade de gerar, interpretar e transformar linguagem natural de forma contextual e coerente os torna ferramentas indispensáveis em diversas aplicações tecnológicas, como chatbots, sistemas de recomendação, assistentes virtuais, análise de documentos e muito mais.

Apesar de seu enorme potencial, seu uso traz desafios éticos, legais e operacionais. Questões como viés algorítmico, privacidade, consumo energético e equidade precisam ser abordadas com seriedade à medida que a tecnologia avança. Além disso, o alto custo computacional exige soluções eficientes, como PEFT e uso estratégico de cache KV, para tornar o uso de LLMs mais sustentável.

A compreensão dos princípios de treinamento, avaliação e escalabilidade é essencial para desenvolver, aplicar e criticar sistemas baseados em LLMs de forma responsável e eficaz. À medida que a área evolui, a combinação entre engenharia de larga escala e consciência ética será crucial para o futuro da IA generativa.