

Modelos Bidirecionais Baseados em Transformers

1. Introdução

Modelos Bidirecionais baseados em Transformer, como o BERT (Bidirectional Encoder Representations from Transformers), revolucionaram o Processamento de Linguagem Natural (PLN) ao introduzirem uma arquitetura capaz de considerar simultaneamente o contexto à esquerda e à direita de cada palavra. Diferentemente dos modelos causais (como GPT), que são utilizados para geração de texto e processam informações apenas da esquerda para a direita, os modelos bidirecionais são especialmente eficazes para tarefas interpretativas, como:

- Identificação de Entidades Nomeadas (NER);
- Análise Sintática (Parsing);
- Rotulação Gramatical (POS Tagging);
- Classificação de texto;
- Extração de informações, entre outras.


2. Diferenças Entre Modelos Causais e Bidirecionais

2.1 Modelos Causais (e.g., GPT)


- Processam o texto da esquerda para a direita;
- São utilizados principalmente para geração de texto;
- Utilizam máscaras no mecanismo de atenção para impedir que os tokens vejam o “futuro”.

2.2 Modelos Bidirecionais (e.g., BERT)

- Consideram o contexto completo da frase (esquerda e direita);
- São voltados para interpretação e compreensão textual;
- Não utilizam máscaras no mecanismo de atenção, permitindo que os tokens acessem informações futuras e passadas.



a) A causal self-attention layer



b) A bidirectional self-attention layer

3. Mecanismo de Atenção Bidirecional

A arquitetura dos modelos bidirecionais é semelhante à dos Transformers tradicionais, mas com uma modificação crítica: a remoção da máscara na matriz de atenção. Isso permite:

- Que cada token observe todos os outros da sequência;
- Maior poder de contextualização para tarefas interpretativas;
- Aprendizado mais robusto de relações sintáticas e semânticas.

4. Pré-processamento de Texto

Antes de alimentar o modelo, o texto passa por uma série de etapas:

- Tokenização em subpalavras (WordPiece, SentencePiece): melhora o tratamento de palavras raras ou desconhecidas;
- Conversão em vetores numéricos, com dimensão fixa (por exemplo, 768);
- Limite de contexto: geralmente 512 tokens por sequência;
- Arquitetura com várias camadas de atenção multi-head sobre esses vetores.

5. Arquiteturas de Modelos

5.1 BERT-base

- 30.000 tokens de vocabulário (WordPiece);
- Entrada com até 512 tokens;
- 12 camadas Transformer;
- 12 cabeças de atenção por camada;
- 768 dimensões por vetor;
- ~110 milhões de parâmetros.

5.2 XLM-RoBERTa (Multilíngue)


- 250.000 tokens (SentencePiece);
- 24 camadas, 16 cabeças de atenção;
- 1024 dimensões por vetor;
- ~550 milhões de parâmetros;
- Suporte a 100 idiomas.

6. Treinamento: Masked Language Modeling (MLM)

O treinamento dos modelos bidirecionais não é feito prevendo o próximo token, mas sim através da tarefa de preenchimento de lacunas (“cloze task”):

1. Seleciona-se aleatoriamente 15% dos tokens da sequência.
2. Para esses tokens:
 - 80% são substituídos por [MASK];
 - 10% são trocados por um token aleatório;
 - 10% permanecem inalterados.
3. O modelo é treinado para prever os tokens originais usando o contexto completo.

Essa abordagem é um exemplo de denoising, onde o modelo aprende a reconstruir entradas corrompidas.



7. Regimes de Treinamento

7.1 Dados Utilizados

- BERT original: ~3,3 bilhões de palavras (Wikipedia + BookCorpus);
- Modelos modernos: datasets massivos como Common Crawl e outros domínios filtrados.

7.2 Objetivos de Treinamento

- MLM (Masked Language Modeling): prever tokens mascarados;
- NSP (Next Sentence Prediction): prever se duas frases são sequenciais;
- RoBERTa removeu NSP, adotando apenas MLM com melhorias no processamento.

7.3 Multilinguismo

- Modelos multilíngues são treinados com dados de vários idiomas;
- Desafio: balanceamento entre línguas com muitos e poucos dados;
- Solução: amostragem com ponderação por frequência usando fator de suavização α (ex.: $\alpha = 0.3$).

8. Embeddings Contextuais

8.1 Definição

São representações vetoriais de tokens considerando o contexto completo de uso, extraídas das últimas camadas do Transformer.

8.2 Vantagens


- Adaptam-se ao contexto de uso da palavra;
- Superam embeddings estáticos (como Word2Vec ou GloVe), que geram apenas um vetor fixo por palavra.

8.3 Aplicações

- Desambiguação Semântica (e.g., “die” em diferentes línguas/sentidos);
- Visualizações (como UMAP) mostram que os sentidos se separam geometricamente.

8.4 Limitações

- Modelos multilíngues podem sofrer transferência negativa;
- O desempenho em línguas com poucos dados tende a ser inferior.



9. Fine-Tuning para Tarefas Específicas

Modelos pré-treinados são adaptados por meio de **fine-tuning** com dados rotulados, geralmente adicionando uma “cabeça” (camada final específica para a tarefa).

10. Tarefas Comuns com Modelos Bidirecionais

10.1 Classificação de Sequências

- Objetivo: atribuir uma única etiqueta a um texto;
- Exemplo: análise de sentimentos;

10.2 Classificação de Pares de Sentenças

- Objetivo: classificar a relação entre duas sentenças (e.g., entailment);
- As sentenças são separadas por [SEP];

10.3 Rotulação de Sequência (e.g., NER)

- Cada token recebe um rótulo (ex.: PER, LOC, ORG);
- Usado para anonimização, extração de entidades, etc.

10.4 BIO Tagging

- **B-XXX**: início de uma entidade;
- **I-XXX**: continuação;
- **O**: fora de entidades;
- Variantes como BIOES oferecem mais precisão para delimitação.

11. Conclusão

Modelos bidirecionais como o BERT e seus derivados marcaram um avanço fundamental no campo de PLN ao permitir que algoritmos compreendam o significado contextual completo das palavras. Essa bidirecionalidade os torna poderosos para tarefas interpretativas, como classificação, extração e rotulação de entidades, embora não sejam ideais para geração de texto.

O treinamento baseado em Masked Language Modeling, aliado à tokenização em subpalavras e à ausência de máscara no mecanismo de atenção, confere a esses modelos uma capacidade robusta de compreensão semântica. Os embeddings contextuais permitem desambiguar significados com precisão, enquanto o fine-tuning permite a adaptação eficiente a diferentes tarefas com baixo custo computacional adicional.

Apesar dos desafios no multilinguismo e no balanceamento entre idiomas, modelos como o XLM-RoBERTa mostram que é possível escalar essas abordagens para centenas de idiomas com resultados competitivos. Como base para diversas aplicações em linguagem natural, os modelos bidirecionais permanecem como um dos pilares centrais da atual revolução na inteligência artificial textual.