


Prompting

1. Introdução

Com o avanço dos Modelos de Linguagem de Grande Escala (LLMs), tornou-se possível realizar tarefas complexas utilizando apenas linguagem natural. Técnicas como prompting, in-context learning e model alignment são centrais para explorar todo o potencial desses modelos.



2. Prompting

2.1 Definição

Prompting consiste em fornecer uma sequência textual (prompt) como contexto para que um LLM gere uma resposta relevante. O modelo gera tokens com base na probabilidade condicional de cada token dado o contexto anterior.

2.2 Engenharia de Prompts (Prompt Engineering)

A criação de prompts eficazes é um processo chamado engenharia de prompts. Um bom prompt deve:

- Conter instruções claras e específicas.
- Estabelecer restrições contextuais (ex: finalizar com "Overall, it was..." em tarefas de sentimento).
- Reduzir ambiguidades.

3. In-Context Learning

3.1 Conceito

In-context learning refere-se à habilidade dos LLMs de aprender a realizar tarefas apenas a partir de exemplos no próprio prompt, sem ajuste dos pesos internos do modelo. Isso significa que o modelo melhora sua resposta com base no contexto e exemplos apresentados, sem necessidade de *gradient updates*.

4. Limitações dos LLMs

Apesar de sua versatilidade, LLMs possuem limitações:

- Baixa aderência a instruções por padrão: Modelos pré-treinados nem sempre seguem comandos de forma precisa.
- Risco de conteúdo prejudicial ou incorreto: Podem gerar respostas tóxicas, ofensivas ou perigosas (ex: conselhos médicos inseguros).

5. Model Alignment

Para mitigar essas falhas, são aplicadas duas técnicas principais:

5.1 Instruction Tuning

Ajuste fino do modelo com um conjunto de instruções e respostas corretas. Isso ensina o modelo a seguir instruções de forma mais confiável.

5.2 Preference Alignment

Envolve treinar um segundo modelo para avaliar o quanto uma resposta se alinha às preferências humanas. Algoritmos comuns:

- RLHF (Reinforcement Learning from Human Feedback)
- DPO (Direct Preference Optimization)

Juntas, essas técnicas compõem o processo de alinhamento do modelo (model alignment), com o objetivo de tornar os modelos úteis e seguros.

6. Chain-of-Thought Prompting

Uma técnica promissora para melhorar o desempenho de modelos de linguagem em tarefas de raciocínio complexo é o **Chain-of-Thought Prompting** (CoT). Essa técnica induz o modelo a seguir um raciocínio passo a passo antes de chegar à resposta final. O procedimento é simples: cada exemplo de demonstração no prompt few-shot é enriquecido com textos que explicam as etapas do raciocínio necessárias para resolver a tarefa. Isso incentiva o modelo a replicar esse padrão lógico, aumentando assim a probabilidade de fornecer respostas corretas em tarefas que exigem múltiplas etapas de inferência.

7. Conclusão

A prática de prompting permite explorar a inteligência dos LLMs sem necessidade de re-treinamento. No entanto, para atingir níveis elevados de utilidade e segurança, é essencial aplicar instruction tuning e preference alignment. Esses componentes garantem que o modelo não apenas compreenda as tarefas, mas também aja de acordo com valores humanos e orientações éticas.